目录

摘要 1
一、 问题重述 2
1.1 问题背景 2
1.2 数据集 2
1.3 问题提出 2
二、 问题分析 3
2.1 问题一：模型构建与效果验证 3
2.2 问题二：区域区分与动态参数调整 3
2.3 问题三：性能评估与优化路径 3
三、 模型假设与符号说明 3
3.1 模型基本假设 3
3.2 符号说明 3
四、 问题一的模型建立与求解 4
4.1 制作训练集 4
4.2 模型建立 5
4.3 模型结果 12
五、 问题二的模型建立与求解 12
5.1 模型建立 12
5.2 模型求解与结果分析 13
六、 问题三的模型建立与求解 13
6.1 优点 13
6.2 缺点 13
6.3 模型改进 14
参考文献 15

题目：潜在指纹增强问题

摘要

低质量潜在指纹图像是指因模糊、噪声、纹线断裂或采集不当导致细节缺失、难以直接识别的指纹图像，其在自动识别系统中存在的特征误判、匹配失效等问题，而传统算法通常将模糊指纹图转化成方向场和频率场，再通过 Gabor 滤波生成修复模糊指纹，其在特别模糊，噪声特别大的指纹图像时表现不佳。本研究基于 MOLF 数据集，提出了一种结合条件生成对抗网络（CGAN）的增强模型，旨在通过深度学习技术来增强潜在指纹的识别精度与效率。

本模型采用 U-Net 架构生成器，通过编码器-解码器结构和跳跃连接修复断裂脊线并增强细节；设计多尺度判别器优化全局与局部生成质量；引入混合损失函数（对抗损失与 L1 像素损失加权）平衡真实性与结构对齐。创新点包括：动态调整低质量区域的对抗损失权重，显著提升模糊区域修复效果；提出门控跳跃连接和梯度协调动态加权策略，进一步优化特征融合与判别器性能。

针对问题一，通过构建基于 CGAN 的指纹增强模型，在测试集上实现了 Rank-5 识别率 34%和 Rank-20 识别率 56%，并通过 PSNR（峰值信噪比）和 SSIM（结构相似性）指标验证了增强图像在像素对齐与结构一致性上的显著提升。

针对问题二，引入区域对抗损失权重矩阵，结合质量评估分数动态调整判别器对不同区域的敏感性，实验表明该方法能有效增强低质量区域的脊线修复效果，尤其在模糊区域（如指纹边缘）的对比度与连续性改善明显。

针对问题三，综合分析模型性能，提出改进方向：通过门控跳跃连接抑制跨层级特征干扰，结合梯度协调动态加权策略优化多尺度判别器训练过程，解决了传统方法在计算效率与复杂场景适配性上的不足。

本研究为低质量指纹图像的高效增强与识别提供了理论支持和技术参考，对刑侦、安防等领域的实际应用具有重要价值。

关键词：条件生成对抗网络；潜在指纹增强；多尺度判别器；U-Net 架构；区域对抗损失

一、 问题重述

1.1 问题背景

自动指纹识别技术作为生物特征识别领域的核心分支，历经长期发展已成为身份认证领域应用最广泛的技术手段之一。其技术实现依托于自动指纹识别系统（AFIS），该系统通过包含图像采集、预处理、特征提取与模式匹配在内的完整处理流程，构建生物特征身份认证体系。当前系统在实际应用中面临着可靠性保障与鲁棒性提升的双重技术挑战，特别是在处理低质量指纹样本时，传统算法存在显著局限性：当面对因表皮损伤、传感器噪声或采集不当导致的图像模糊、纹线断裂等质量退化问题时，系统易出现特征误判、匹配失效等问题，从而导致认证准确率下降与系统运行效率降低等现实困境。这种技术瓶颈严重制约了指纹识别系统在复杂应用场景中的部署效果。在此背景下，本研究基于 MOLF（Multi-sensor Optical And Latent Fingerprint Database）数据集中的 720 个指纹（包括训练集（600）和测试集（120）），利用 Gabor 滤波对训练集中的潜在指纹图进行增强，然后针对潜在指纹图像低质量特点，训练条件生成对抗网络(Conditional Generative Adversarial Network,CGAN)，提升潜指纹图像质量，满足后续阶段指纹特征提取和识别的要求。

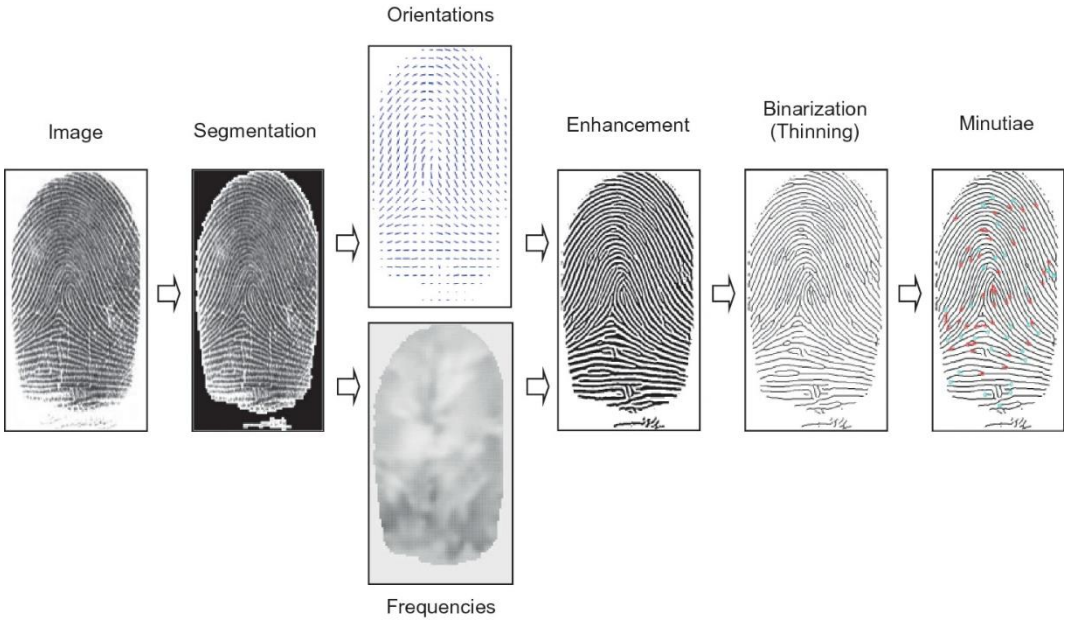


图 1 指纹图像处理与特征提取流程图

1.2 数据集

附件给出了数据集和指纹识别软件，其中训练集文件 Example Data 中有 latent 文件夹包括 600 张潜指纹和 gallery 文件夹包括这 600 张潜指纹的清晰库指纹，验证集文件 Test Latent 包括 120 张潜指纹图片，

1.3 问题提出

问题一：如何建立强化算法模型，在训练集上计算并分析 Rank-5 与 Rank-20 识别率，同时评估算法效率等核心指标。

问题二：如何在模型中区分指纹图像的质量差异区域，并通过参数敏感性分析量化关键参数对识别结果的影响。

问题三：如何客观分析传统方法的优劣，提出改进方向以解决计算效率与低质量指纹场景的适配性问题。

二、 问题分析

2.1 问题一：模型构建与效果验证

需设计基于深度学习的增强模型（如 CGAN），在训练集上验证其提升 Rank-5 和 Rank-20 识别率的有效性，并通过计算推理时间、内存占用等指标评估算法效率，确保刑侦场景的实用性。。

2.2 问题二：区域区分与动态参数调整

应引入注意力机制或多尺度特征融合，区分指纹的高/低质量区域；通过调整损失权重、判别器层级等参数进行敏感性实验，量化不同参数对识别率的影响，优化模型鲁棒性。

2.3 问题三：性能评估与优化路径

基于识别率、计算效率、泛化性等指标维度分析强化模型的优劣，提出改进方向，解决模型计算复杂度高等问题。

三、 模型假设与符号说明

3.1 模型基本假设

（1）假设潜在指纹空间 X 与库指纹空间 Y 的差异主要由质量退化（如噪声、断裂、模糊）引起，而非指纹身份信息差异。

（2）假设给定匹配器 F 在指纹特征相似性度量上是稳定的，即匹配分数仅由指纹质量与特征一致性决定，与输入顺序或外部干扰无关。

（3）假设强化学习（RL）可通过动态调整生成策略（如 CGAN 的生成器参数）优化匹配奖励信号（Rank-N 识别率），而非依赖传统固定损失函数（如 MSE）。

（4）假设指纹图像中存在局部质量差异（如核心区域清晰、边缘模糊），可通过注意力机制或多分支网络区分处理，提升关键区域增强权重。

3.2 符号说明

表 1 符号说明

符号	含义
X	潜指纹空间，包含低质量指纹图像

Y	库指纹空间，包含高质量指纹图像
G	生成器，映射$X \to Y$，负责增强潜指纹
D	判别器，判断输入图像是真实图像/生成图像
F	指纹匹配器，计算两指纹的相似性分数$F(x,y) \in [0,1]$
$R(G(X),Y,n,F)$	增强后的$Rank-n$识别率，衡量匹配成功率
$\mathcal{L}_{GAN}$	生成器的对抗损失
$\mathcal{L}_{L1}$	生成器的$L1$像素级损失
λ	L_1损失的权重系数
$DownBlock$	下采样模块，用于特征提取和降维
$UpBlock$	上采样模块，用于图像重建和升维
$MS-Disciminator$	多尺度判别器，处理不同分辨率的图像
$\oplus$	特征图的通道拼接操作
$\otimes$	卷积操作
$\mathbb{I}(\cdot)$	指示函数，条件满足时输出 1，否则 0
$\mathbb{E}_{x,y}$	对变量x和y的联合分布的$p(x,y)$求数学期望

四、 问题一的模型建立与求解

4.1 制作训练集

潜指纹识别问题的一大难点在于潜指纹数据集的缺少。要想训练一个能够修复模糊指纹的深度学习模型，除了潜指纹，还要有其对应的分割增强标签，而这通常是难以获取的。对于潜指纹数据缺乏的问题，目前研究者们通用的做法是使用图像融合等手段人工构建潜指纹数据集。本文利用比赛官方给的 gallery 高清图片，通过将其模糊化，得到模型训练数据。

对于 gallery 集合中的指纹，对其进行旋转和平移

$$\begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} \tag{1}$$

$$\begin{bmatrix} x' \\ y' \end{bmatrix} = \begin{bmatrix} x \\ y \end{bmatrix} + \begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix} \tag{2}$$

对变换后的指纹分别进行模糊处理
高斯模糊

$$Ga(x,y) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}} \tag{3}$$

方框模糊

$$B(x,y) = \begin{cases} \dfrac{1}{(2r+1)^2} & \text{if } |x| \le r \text{ and } |y| \le r \\ 0 & \text{otherwise} \end{cases} \tag{4}$$

运动模糊

$$K_v = \begin{bmatrix} 0 & \frac{1}{k} & 0 \\ \vdots & \vdots & \vdots \\ 0 & \frac{1}{k} & 0 \end{bmatrix}_{k\times k} \tag{5}$$

输出几何变化和模糊处理之后的 gallery 图像作为模型训练的训练集

$$I_{\text{out}} = \mathcal{B}(\mathcal{T}(\mathcal{R}(I_{\text{in}}))) \tag{6}$$

其中：I_{in}是输入图像，$\mathcal{R}$是旋转操作，$\mathcal{T}$是平移操作，$\mathcal{B}$是模糊操作。

4.2 模型建立

步骤 1：数据预处理与目标函数构建。潜指纹图像普遍存在噪声干扰、模糊不清以及局部断裂等问题，这些问题严重影响了后续指纹匹配的精度。此外，原始图像的像素值分布和尺寸差异会降低模型训练的稳定性和效率。因此，数据预处理的核心目标是通过规范化操作统一输入数据的分布和尺寸，为后续模型训练提供高质量、一致性的输入。

归一化公式如下：

$$I_{\text{norm}} = \frac{I_{\text{raw}} - 127.5}{127.5} \Rightarrow I_{\text{norm}} \in [-1,1] \tag{7}$$

其中，I_{raw}为原始图像像素值（0~255），I_{norm}为归一化后的图像，取值范围被映射为[-1, 1]，此操作的目的是将输入数据分布中心化，减少模型对数据尺度的敏感性。

条件生成对抗网络（CGAN）是生成对抗网络的改进版本，通过在生成器和判别器的输入中引入条件信息（如类别标签或模态数据），实现对生成过程的定向控制。在潜指纹增强任务中，CGAN 可利用低质量指纹的结构特征作为条件输入，引导生成器修复断裂脊线并增强细节点，从而提升匹配精度。CGAN 的目标函数要求判别器在评估生成样本真实性的同时，验证其与条件信息的匹配性，数学上体现为联合优化真实数据分布与条件约束的对抗损失：

$$\min_G \max_D V(D,G) = \mathbb{E}_{x,y}[\log\ D(x|y)] + \mathbb{E}_{z,y}[\log\,(1 - D(G(z|y)|y))] \tag{8}$$

其中，y 为条件信息，确保生成样本 $G(z \mid y)$既逼真又与 y 语义一致。

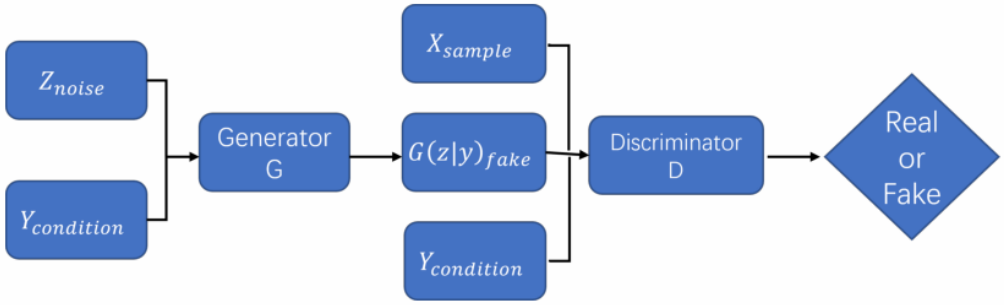


图 2 CGAN 结构示意图

步骤 2：生成器设计（U-Net 架构）。潜指纹增强的关键在于恢复断裂的脊线、去除噪声，并增强细节点（如分叉和端点）的清晰度。传统的卷积网络难以同时捕获全局结构和局部细节，因此需要一种能够融合多尺度特征的架构。U-Net 的编码器-解码器结构结合跳跃连接（Skip Connections），能够在降采样过程中提取抽象特征，并在上采样时通过跳跃连接保留细节信息（如脊线走向和指纹形态特征），从而解决潜指纹的结构修复问题。生成器 G的数学定义基于 U-Net 架构，包含编码器（下采样）和解码器（上采样）两部分。

① 编码器（特征提取）： 编码器由连续的下采样块（$DownBlock$）组成，每层通过卷积操作实现分辨率减半，通道数倍增，第 l 层的特征图计算公式为：

$$z_l = \text{LeakyReLU}\big(\text{BatchNorm}(\text{Conv2d}(z_{l-1}; \mathbf{W}_l^{\text{enc}}))\big) \tag{9}$$

其中，$Conv2d$ 为步长 2 的卷积核，实现分辨率减半, $\mathbf{w}_l^{\text{enc}}$为编码器第 l 层的权重参数。

② 解码器（图像重建）：解码器通过反卷积（上采样）与编码器的跳跃连接（特征拼接）恢复图像分辨率，每层融合编码器对应层的语义信息，第l层的特征图计算为：

$$\hat{z}_l = \text{ReLU}\left(\text{BatchNorm}\big(\text{ConvTranspose2d}(z_l \oplus z_{L-l}; \mathbf{W}_l^{\text{dec}})\big)\right) \tag{10}$$

其中，$\oplus$表示特征图的通道拼接操作，将编码器第 L–l 层的特征与解码器第 l 层的特征融合，$ConvTranspose2d$ 为反卷积操作，实现分辨率加倍。

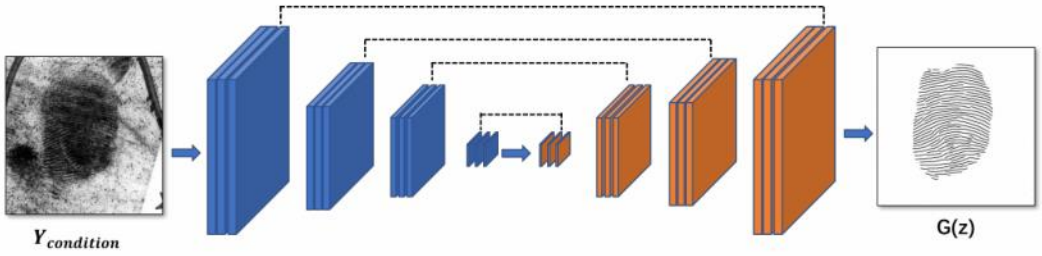


图 3 生成器结构

步骤 3：判别器设计（多尺度架构）。传统的单一判别器仅能在固定分辨率下评估图像真伪，而指纹的细节点（如脊线分叉）和全局结构（如核心区形态）需要不同尺度的判别能力。因此，采用多尺度判别器（Multi-Scale Discriminator），分别在完整分辨率（512x512）、半分辨率（256x256）和四分之一分辨率（128x128）下进行判别，以全面提升生成图像的视觉质量和匹配精度。

多尺度判别器的输出为各尺度判别结果的加权和：

$$D_{\text{multi}}(x,y)=\sum_{s\in\{1,0.5,0.25\}} D_s(x_{\downarrow s},y_{\downarrow s}) \tag{11}$$

其中，$x_{\downarrow s}$和$y_{\downarrow s}$表示输入指纹和真实对应指纹下采样至分辨率 $s\times 512\times 512$，D_s为对应尺度的子判别器，其结构相同但参数独立。

每个子判别器由卷积层、激活函数和谱归一化（Spectral Normalization）组成，谱归一化用于稳定训练过程，计算流程为：

$$D_s(x,y)=\sigma(\mathbf{W}_5\cdot\phi(\mathbf{W}_4\cdot\phi(\mathbf{W}_3\cdot\phi(\mathbf{W}_2\cdot\phi(\mathbf{W}_1\cdot[x;y])))))\tag{12}$$

其中，ϕ表示$LeakyRelU$激活函数，σ为$Sigmoid$函数，$[x;y]$表示将输入图像x和目标图像y沿通道维度拼接。

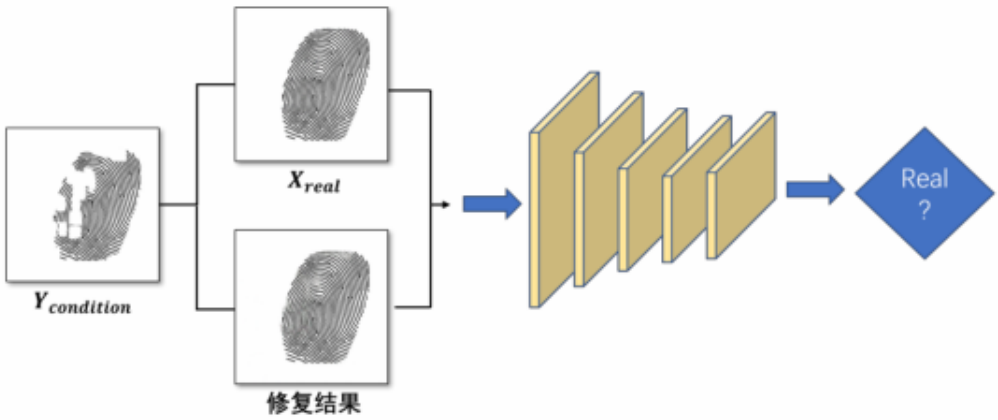


图 4 判别器结构

步骤 4：损失函数设计。生成对抗网络的训练需要平衡两种目标：生成图像的真实性（通过对抗损失）和结构一致性（通过像素级损失）。单纯依赖对抗损失可能导致生成图像出现伪影或结构扭曲，而仅使用像素损失则会限制生成器的创造力。因此，本模型采用混合损失函数，结合对抗损失（$\mathcal{L}_{GAN}$）和 L1 像素损失（$\mathcal{L}_{L1}(G)$），以兼顾图像逼真度与细节点对齐。

① 对抗损失（Adversarial Loss）：生成器 G 试图生成判别器 D 无法区分的图像，而判别器 D 则努力区分真实图像和生成图像。其数学形式为：

$$\mathcal{L}_{GAN}(G,D)=\mathbb{E}_{x,y}[\log D(x,y)]+\mathbb{E}_x\left[\log\left(1-D\left(x,G(x)\right)\right)\right]\tag{13}$$

生成器 G 的目标是最小化 $\mathcal{L}_{GAN}$，而判别器 D 的目标是最大化它。

② L1 像素损失（Pixel-wise L1 Loss）：为了强制生成图像与目标图像在像素级对齐，引入 L1 损失：

$$\mathcal{L}_{L1}(G) = \mathbb{E}_{x,y}[\| G(x) - y \|_1] \tag{14}$$

其中，$\|\cdot\|_1$ 表示 L1 范数，即逐像素绝对误差之和。

③ 总损失函数：生成器的总损失为对抗损失与 L1 损失的加权和：

$$\mathcal{L}_{Total} = \mathcal{L}_{GAN} + \lambda \cdot \mathcal{L}_{L1} \tag{15}$$

其中，$\lambda = 50$ 是权重系数，用于平衡两种损失的重要性。

步骤 5：模型训练。在生成对抗网络的训练过程中，生成器（Generator）和判别器（Discriminator）的优化目标存在天然的对立性：生成器试图生成逼真的图像以欺骗判别器，而判别器则努力区分真实图像与生成图像。这种对抗性导致两者的收敛速度不一致，若采用相同的学习率，可能导致训练不稳定或模式崩溃（Mode Collapse）。因此，本步骤的核心目标是通过动态调整生成器和判别器的学习率，平衡两者的训练速度，确保模型稳定收敛。

① 优化器设置 生成器和判别器均采用 Adam 优化器，但其学习率（Learning Rate）设置为不同值，其中生成器学习率为$\eta_G = 1 \times 10^{-4}$，判别器学习率为$\eta_D = 4 \times 10^{-4}$，这一设置的数学依据是：

$$\begin{aligned} \theta_G &\leftarrow \theta_G - \eta_G \nabla_{\theta_G} (\mathcal{L}_{GAN} + \lambda \mathcal{L}_{L1}) \\ \theta_D &\leftarrow \theta_D - \eta_D \nabla_{\theta_D} \mathcal{L}_{GAN} \end{aligned} \tag{16}$$

其中，θ_G 和 θ_D 分别表示生成器和判别器的参数。∇ 为梯度运算符，$\lambda = 50$ 为 L1 损失的权重系数。判别器采用更高学习率的目的是使其更快收敛，从而为生成器提供更稳定的梯度信号。

② 训练循环设计 每个训练周期（Epoch）内，按以下步骤迭代更新模型参数：判别器更新：固定生成器参数，通过最小化判别器损失 $\mathcal{L}_{\text{GAN}}$ 更新 θ_D。生成器更新：固定判别器参数，通过最小化总损失 $\mathcal{L}_{\text{Total}}$ 更新 θ_G。 这一交替更新策略可形式化表示为：

$$\begin{aligned} \theta_D^{(t+1)} &= \theta_D^{(t)} - \eta_D \cdot \frac{1}{B} \sum_{i=1}^{B} \nabla_{\theta_D} \mathcal{L}_{\text{GAN}}^{(i)} \\ \theta_G^{(t+1)} &= \theta_G^{(t)} - \eta_G \cdot \frac{1}{B} \sum_{i=1}^{B} \nabla_{\theta_G} \left(\mathcal{L}_{\text{GAN}}^{(i)} + \lambda \mathcal{L}_{\text{L1}}^{(i)} \right) \end{aligned} \tag{17}$$

其中，B 为批次大小（Batch Size），代码中设为 4，t 表示训练迭代次数。下图为模型在 epoch=6 时对模糊数据的恢复效果(左端是原始模糊训练集图像，右端是高清图像，中间是 CGAN 的生成器生成的图像)。

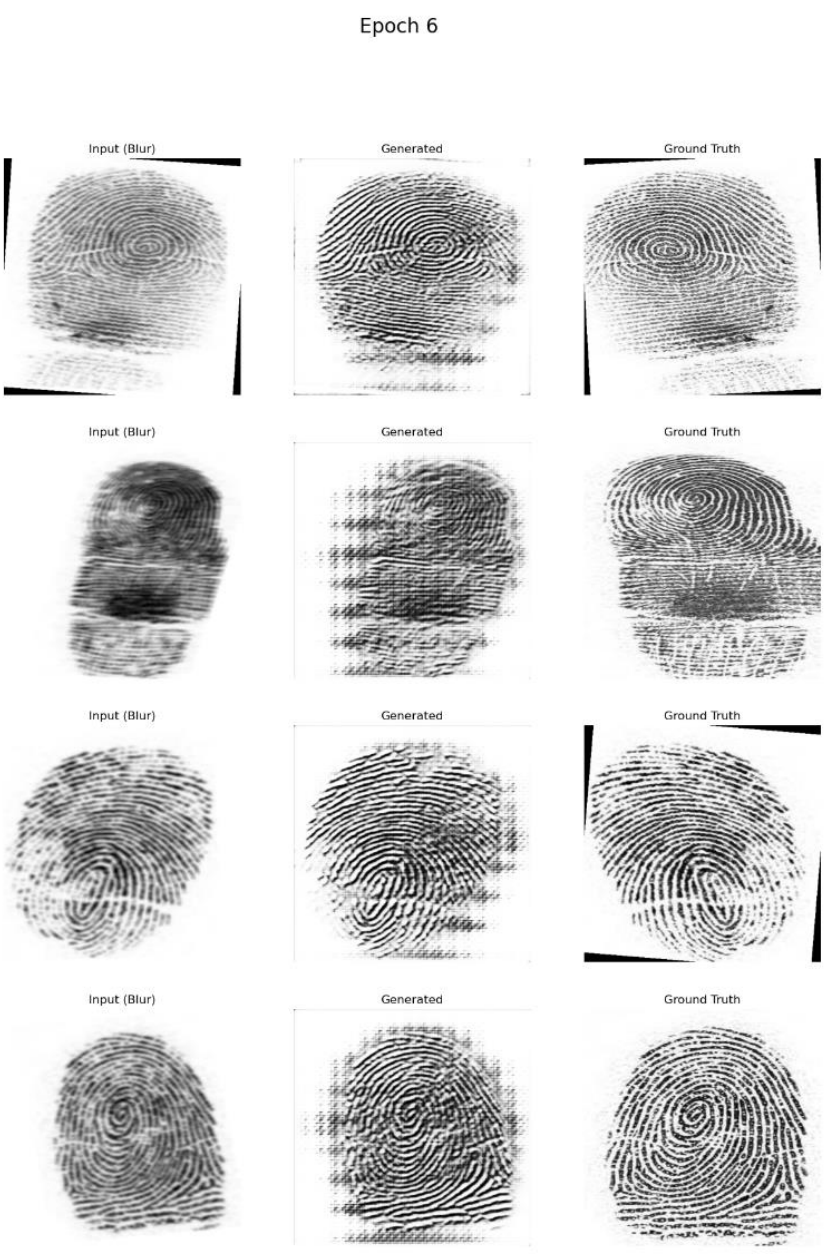


图 5 模型回复效果对比图

看到生成器把模糊的脊线变得更加清晰，同时修复了一些断裂点。

步骤 6：模型验证与指标。指纹增强算法的最终目标是提高刑侦场景中的指纹识别精度。因此，需通过客观指标量化增强效果，并验证算法在实际应用中的可行性。

① Ran-k 识别率。给定增强后的潜指纹集合 $G(X)$ 和库指纹集合 Y ,Rank-n 识别率定义为：

$$R(G(X),Y,n,F)=\frac{1}{N}\sum_{i=1}^{N}\mathbb{I}\left(F(G(x_i),y_i)\in Top-n(S_i)\right) \tag{18}$$

其中，N 为测试集样本数量(120 对)， $\mathbb{I}(\cdot)$ 为指示函数,当条件满足时取值为 1,否则为 0，$S_i = \{F(G(x_i), y_j) \mid y_j \in Y\}$ 表示测试样本 x_i 与所有库指纹 y_j 的匹配分数集合，Top-n (S_i) 表示 S_i 中分数最高的前 n 个值，该指标直接反映了增强算法在真实匹配场景中的有效性。对于题目中给定的 Latent 模糊指纹图，将其输入到训练好的生成器中，得到强化图。下图是 Latent 数据中 45_4 原始图和加强图的对比



图 5:Latent **中的数据加强对比图**

可以看到增强算法从分割后的指纹区域中分辨出脊线和谷线的纹理，增强了脊线对比度，在一定程度上实现了二值化。本方法能够明显提高潜指纹图像的质量及指纹脊线的质量和对比度。

② 峰值信噪比 PSNR (Peak Signal-to-Noise Ratio)

均方误差$MSE\ (Mean\ Squared\ Error)$指的是真实值与预测值之间误差的平方和均值。在图像上, 对于大小为$m \times n$ 两幅灰度图像 I 和 K ,在两幅图像具有相似噪声的情况下,它们之间的均方误差定义为:

$$MSE = \frac{1}{mn}\sum_{i}^{m}\sum_{j}^{n}\left(I(i,j) - K(i,j)\right)^2 \tag{19}$$

其中，$I(i,j)$ 指的是图像 I 在(i,j)处的像素值。

通过 MSE 可以计算出 PSNR, 其表达式如下:

$$PSNR = 20 * \log_{10}\left(\frac{MAX_i}{\sqrt{MSE}}\right) \tag{20}$$

其中，对数计算中的分子是灰度图像像素的最大值。对 8 位灰度图像而言 $MAX_i = 255$ ，PSNR 的值越大,表示图像的质量越高。根据图，可以看到增强后的指纹图沿脊线的 PSNR 变高，说明脊线更加明显。



图 6 PSNR 结果图

③ 结构相似性 SSIM (Structural Similarity)

SSIM 可以衡量两张图像的相似程度，也可以反映图像的失真程度。不同于 MSE 和 PSNR,SSIM 是一种感知模型,更能反映人眼的直观感受。结构相似性指数主要衡量图像的三个特征：亮度、对比度和结构。衡量亮度通过计算所有像素的平均值得到，衡量对比度以图像的灰度标准差计算，衡量结构以归一化相关性系数估计。当三种特征在 SSIM 衡量中的占比都为 1 时，那么 SSIM 的计算表示为:

$$SSIM(X,Y) = \frac{(2\mu_x\mu_y + C_1)(2\delta_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\delta_x^2 + \delta_y^2 + C_2)} \tag{21}$$

其中，X 和 Y 代表两张图像，μ_x 和 μ_y 分别表示 X 和 Y 的灰度均值；δ_x^2 和 δ_y^2 分别表示图像的方差；δ_{xy} 表示两张图像的协方差；常数 C_1 和 C_2 是为了避免分母为 0 的情况。下图是 CGAN 增强前后的 SSIM 值，为 0.467，表明修复较好。

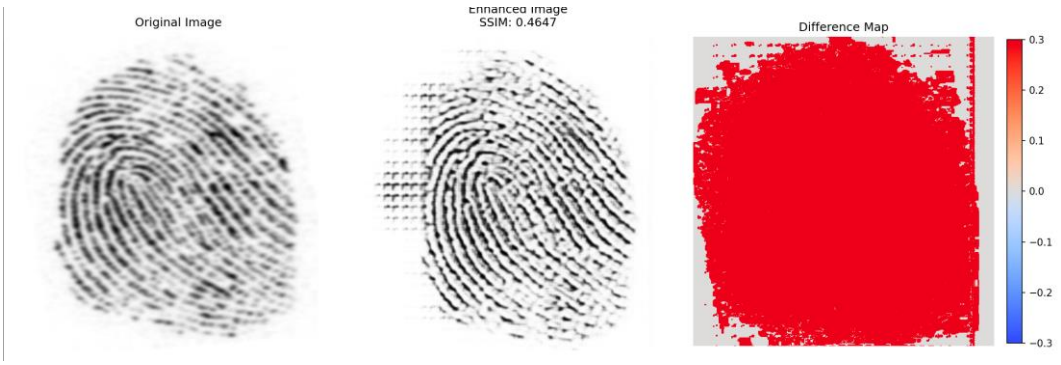


图 7　SSIM 结果图

4.3 模型结果

将 Latent 文件中的所有图片输入训练好的生成器，得到加强后的图片，然后根据题中给的 rank-n 准确率的计算公式，得到 rank-5 和 rank-20。结果如下：

表 2 问题一结果

指标	结果
rank-5	34%
rank-20	56%

五、 问题二的模型建立与求解

5.1 模型建立

针对潜在指纹存在质量差异的区域，我们选择在损失函数中加入区域加强对抗损失，来区分质量差异，进而有侧重的去训练模型。
原始的最小二乘对抗损失如下:

$$\mathcal{L}_{adv} = E_x\left[\left(D\left(G(x)\right)-1\right)^2\right] + E_{x,y}[(D(y)-1)^2] \tag{22}$$

通过引入一个质量权重矩阵$W(x)$，其中$W_{ij} \in [1,2]$表示像素位置(I, j)的权重，低质量区域权重更高，改进后的生成器损失:

$$\mathcal{L}_{adv}^{weighted} = E_x\left[W(x) \odot \left(D\left(G(x)\right)-1\right)^2\right] \tag{23}$$

W(x)的构造方法如下:

$$W_{ij} = 1 + \frac{1}{1+e^{-k(Q_{ij}-T)}} \tag{24}$$

其中$Q(ij)$是质量评估分数，K 是斜率系数，控制权重变化速度。

5.2 模型求解与结果分析

由于对 600 张潜指纹计算 rank 准确率过于耗费时间资源，我们通过在训练 CGAN 过程中生成器产生的图像对比来看加入区域加强对抗损失之前和之后的模型效果



图 8 潜在指纹的强化对比图

左图是模糊图像，中间是没有加入区域加强对抗损失的图像，可以看到在指纹左侧，原图黑成一团，导致原始的 CGAN 无法成功复原，而加入了区域加强对抗损失之后，质量差的区域质量权重变高，判别器对这块区域的判别要求就会变高，自然能训练出更准确的图片。

六、 问题三的模型建立与求解

6.1 优点

(1)多尺度特征融合能力卓越：基于 U-Net 的编码器-解码器架构,通过跳跃连接实现跨层级特征融合,编码器的下采样过程有效提取指纹的全局语义信息(如核心区形态),而解码器的上采样结合浅层特征恢复局部细节(如脊线分叉与端点)。这种对称结构理论上保证了多级特征的精准对齐,兼顾全局结构完整性与局部纹理真实性。

(2)判别器多尺度感知机制高效：采用全分辨率、半分辨率与四分之一分辨率的三尺度判别器并行架构,迫使生成器在不同粒度上与真实分布对齐——高分辨率判别器关注像素级精度(高频噪声抑制),低分辨率判别器聚焦全局结构一致性 (低频形态修复)。谱归一化技术的引入进一步稳定训练过程,通过约束权重矩阵的谱范数($IIWII_2 \leq 1$) ,在限制 Lipschitz 常数的同时保留判别器对高频特征的敏感性,相较于传统权重裁剪更具数学严谨性。

(3)损失函数设计互补性强：对抗损失($\mathcal{L}_{GAN}$)通过最小化生成分布与真实分布的 JS 散度,驱动生成图像逼近真实指纹的统计特性；L1 像素损失 ($\mathcal{L}_{L1}$) 则作为强正则项,约束生成图像与目标图像的逐像素对齐。二者的线性组合 ($\mathcal{L}_{Total} = \mathcal{L}_{GAN} + \lambda\mathcal{L}_{L1}$) 在优化过程中平衡了生成多样性与结构保真度,有效避免模式崩溃问题。

6.2 缺点

(1)跨层级特征融合机制存在干扰：解码过程中直接将浅层特征(如脊线纹理)与深层语义特征(如指纹类别)拼接,可能导致不同抽象层级特征的竞争。例如,在高层解码阶

段,深层特征可能主导重建过程,抑制浅层细节的恢复,致使局部纹线断裂修复不彻底。

(2)方向场约束建模不足：当前模型仅通过损失函数叠加方向场误差,未能将方向感知机制嵌入网络结构。指纹脊线的方向场是其关键拓扑特征,若未在卷积操作中显式建模(如方向自适应卷积),生成器难以从根本上学习脊线的连续性规律,导致增强后纹线走向不自然。

(3)深度可分离卷积适配性有限：采用深度可分离卷积(逐通道卷积+逐点卷积)虽降低了参数量,但牺牲了空间-通道的联合建模能力。指纹图像具有强方向性与周期性纹理特性,标准卷积的空间局部相关性建模更适用于此类结构,而深度可分离卷积可能削弱方向敏感特征的提取,导致细节点模糊。

6.3 模型改进

(1)门控跳跃连接机制：在跳跃连接中引入可学习的门控权重 G_l ,动态调节浅层特征的贡献度：

$$\ddot{d}_l = G_l \odot e_{L-l} + (1 - G_l) \odot Deconv(d_{l-1}) \tag{25}$$

其中, $G_l \in [0,1]$ 通过注意力机制生成,允许网络自适应筛选有价值的细节特征,抑制噪声或冗余信息的传递,从而提升跨层级特征融合的有效性。

(2)梯度协调动态加权策略：为多尺度判别器损失分配时变权重系数 $\alpha_s(t)$,优化训练过程的阶段性目标:

$$\mathcal{L}_D = \sum_{s \in f,h,q} \alpha_s(t) \left[\mathbb{E}[D_s(x_{\text{real}})] - \mathbb{E}\left[D_s\left(G(x_{\text{blur}})\right)\right] \right] \tag{26}$$

其中, s 表示判别器尺度(全/半/四分之一分辨率), $\alpha_s(t)$ 随训练步数 t 动态调整。初期(t 较小时)侧重低分辨率判别器以稳定全局结构生成,后期(t 较大时)增大高分辨率判别器权重以细化局部纹理,实现训练过程的渐进式优化。

参考文献

[1]黄宜.基于深度字典学习的低质量指纹增强方法的研究[D].安徽师范大学,2024.DOI:10.26920/d.cnki.gansu.2024.000233.
[2]王成玉.基于生成对抗模型的潜指纹图像增强与修复[D].西安电子科技大学,2023.DOI:10.27389/d.cnki.gxadu.2023.000649.